

Übungen zur Einf. in Deep Learning für Visual Computing

Sommersemester 2023
Dozent: Prof. Dr. Reinhard Klein
Tutorin: Alina Pollehn

Übungsgruppe 3
Ilia Mirkis

Übungsblatt 1

26.04.2023

Aufgabe a)

Case: Regression von Surface Reflectance Parametern

Klasse von Aufgaben T

Eine Klasse von Aufgaben bezüglich dieser Problemstellung besteht aus Computationsaufgaben, die Images als Eingabe bekommen und verschiedene numerische Reflectance-Parametern (z.B. Reflexionskoeffizient), die dem Image entsprechen, calculieren können.

Performanz-Maß P

Zur Regression können wir MSE benutzen:

$$\text{MSE}(\hat{\theta}_m) = \mathbb{E} \left[(\hat{\theta}_m - \theta)^2 \right]$$

Erfahrung E

Wir können *supervised learning algorithm* benutzen. Als Dataset wird die Menge der Paaren ("Element", "Erwartungswert") benutzt.

Case: Klassifikation von MNIST Bildern

Klasse von Aufgaben T

Eine Klasse von Aufgaben bezüglich dieser Problemstellung besteht aus Entscheidungsaufgaben, die entscheiden, zu welcher von k Kategorien eine Eingabe gehört.

Performanz-Maß P

Zu den Klassifikationsproblemen können wir logloss Funktion (äq. Kreuz-Entropie) benutzen (als Ergebnis wird NN einen Wahrscheinlichkeitsvektor ausgeben):

$$\text{Logloss} = -\frac{1}{N} \sum_{i=1}^N y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$$

Erfahrung E

Wie im obigen Case kann man als Dataset die Menge der Paaren ("Element", "richtige Kategorie") benutzen, um unser NN zu trainieren.

Aufgabe b)

Teil 1

$$P(X = i, Y = j) = \begin{cases} p(i)^2, & \text{falls } i = j \\ 2 \cdot p(i) \cdot p(j), & \text{falls } i < j \\ 0, & \text{falls } i > j \text{ (weil } \min \leq \max) \end{cases}$$

$$P_X(i) = p(i)^2 + 2p(i) \cdot \sum_{j=i+1}^6 p(j) \implies \begin{cases} P_X(1) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(4 \cdot \frac{1}{10} + \frac{1}{2}\right) = \frac{19}{100} \\ P_X(2) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(3 \cdot \frac{1}{10} + \frac{1}{2}\right) = \frac{17}{100} \\ P_X(3) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(2 \cdot \frac{1}{10} + \frac{1}{2}\right) = \frac{15}{100} \\ P_X(4) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(1 \cdot \frac{1}{10} + \frac{1}{2}\right) = \frac{13}{100} \\ P_X(5) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \frac{1}{2} = \frac{11}{100} \\ P_X(6) = \left(\frac{1}{2}\right)^2 = \frac{1}{4} \end{cases}$$

$$P_Y(i) = p(i)^2 + 2p(i) \cdot \sum_{j=1}^{i-1} p(j) \implies \begin{cases} P_Y(1) = \left(\frac{1}{10}\right)^2 = \frac{1}{100} \\ P_Y(2) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \frac{1}{10} = \frac{3}{100} \\ P_Y(3) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(2 \cdot \frac{1}{10}\right) = \frac{5}{100} \\ P_Y(4) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(3 \cdot \frac{1}{10}\right) = \frac{7}{100} \\ P_Y(5) = \left(\frac{1}{10}\right)^2 + 2 \cdot \frac{1}{10} \cdot \left(4 \cdot \frac{1}{10}\right) = \frac{9}{100} \\ P_Y(6) = \left(\frac{1}{2}\right)^2 + 2 \cdot \frac{1}{2} \cdot \left(5 \cdot \frac{1}{10}\right) = \frac{3}{4} \end{cases}$$

$$P(X = 6 | Y = 6) = \frac{P(X = 6, Y = 6)}{P(Y = 6)} = \frac{\left(\frac{1}{2}\right)^2}{\frac{3}{4}} = \frac{1}{3}$$

$$P(X = 1 | Y = 3) = \frac{P(X = 1, Y = 3)}{P(Y = 3)} = \frac{2 \cdot \frac{1}{10} \cdot \frac{1}{10}}{\frac{5}{100}} = \frac{2}{5}$$

$$P(Y = 3 | X = 1) = \frac{P(X = 1 | Y = 3) \cdot P(Y = 3)}{P(X = 1)} = \frac{\frac{2}{5} \cdot \frac{5}{100}}{\frac{19}{100}} = \frac{2}{19}$$

$$P(X = 6 | Y = 2) = \frac{P(X = 6, Y = 2)}{P(Y = 2)} = \frac{0}{\frac{3}{100}} = 0$$

Teil 2

$$P(A) = \frac{N(A)}{N_{\text{total}}} \implies P(X = 6 | Y = 6) = \frac{N(X = 6, Y = 6)}{N(Y = 6)} = \frac{4}{12} = \frac{1}{3}$$

Analog können wir andere Wahrscheinlichkeiten finden:

$$P(X = 1 | Y = 3) = \frac{N(X = 1, Y = 3)}{N(Y = 3)} = \frac{2}{5}$$

$$P(Y = 3 | X = 1) = \frac{N(X = 1, Y = 3)}{N(X = 1)} = \frac{2}{19}$$

$$P(X = 6 | Y = 2) = \frac{N(X = 6, Y = 2)}{N(Y = 2)} = \frac{0}{5} = 0$$

Aufgabe c)

Zuerst beweisen wir, dass $\text{MSE}(\hat{\theta}_m) = \text{Bias}(\hat{\theta}_m)^2 + \text{Var}(\hat{\theta}_m)$

$$\text{MSE}(\hat{\theta}_m) = \mathbb{E}[(\hat{\theta}_m - \theta)^2] = \mathbb{E}[\hat{\theta}_m^2 - 2\hat{\theta}_m \cdot \theta + \theta^2] = \mathbb{E}[\hat{\theta}_m^2] - 2\theta \cdot \mathbb{E}[\hat{\theta}_m] + \theta^2$$

$$\begin{aligned} \text{Bias}(\hat{\theta}_m)^2 + \text{Var}(\hat{\theta}_m) &= \left(\mathbb{E}[\hat{\theta}_m] - \theta\right)^2 + \mathbb{E}[\hat{\theta}_m^2] - \mathbb{E}[\hat{\theta}_m]^2 = \mathbb{E}[\hat{\theta}_m]^2 - 2\theta \cdot \mathbb{E}[\hat{\theta}_m] + \theta^2 + \mathbb{E}[\hat{\theta}_m^2] - \mathbb{E}[\hat{\theta}_m]^2 = \\ &= \mathbb{E}[\hat{\theta}_m^2] - 2\theta \cdot \mathbb{E}[\hat{\theta}_m] + \theta^2 \end{aligned}$$

Da die rechten Seiten gleich sind, folgt daraus die ursprüngliche Behauptung. \square

Diese zwei Gründen sind *Underfitting* und *Overfitting*.

Underfitting kann auftreten, falls unser Modell zu geringe Kapazität hat (sehr einfach ist). In diesem Fall ist der Bias hoch, weil die wahren Parametern θ nicht korrekt durch $\hat{\theta}$ approximiert werden können.

Overfitting kann auftreten, falls unser Modell zu hohe Kapazität hat ("too complicated" ist). In diesem Fall wird die Varianz hoch, weil es viele verschiedene Möglichkeiten für $\hat{\theta}$ gibt, die selben Daten zu approximieren.

Modelkapazität hängt von Hyperparameter ab. Deshalb ist es beim Wahl von Hyperparametern sehr wichtig, Bias/Varianz Trade-off zu finden, weil es zur bessere Generalisierung führt.